

Clustering de Variables et Modalités

Algorithmes et Outils pour l'Interprétation des Résultats

Package R : `VarClustering`

Eugénie Barlet

Modou Mboup

Axel Cano

M2 SISE 2024-2025

Université Lyon 2

24 novembre 2025

Résumé

Ce rapport présente le développement d'un package R complet pour le clustering de variables et de modalités, des techniques d'analyse exploratoire visant à regrouper des variables corrélées ou des catégories similaires en clusters homogènes. Nous proposons l'implémentation de trois algorithmes complémentaires : **HClustVar** pour le clustering hiérarchique de variables (quantitatives, qualitatives ou mixtes), **KmeansVariables** pour le clustering par k-means de variables quantitatives, et **ModCluster** pour le clustering de modalités basé sur la distance de Dice. Le package `VarClustering` offre des outils d'aide à la décision pour la sélection automatique du nombre de clusters (méthodes du coude et silhouette) et des visualisations riches (dendrogrammes, projections factorielles, silhouettes). Une application Shiny interactive permet d'utiliser les fonctionnalités du package sans connaissance approfondie de R.

Table des matières

1	Introduction	3
1.1	Contexte et motivation	3
1.2	Objectifs du projet	3
1.3	Structure du rapport	3
2	Méthodologie	3
2.1	Clustering de variables vs clustering d'observations	3
2.2	Approches existantes	4
2.3	Choix des algorithmes	4
3	Algorithmes implémentés	5
3.1	HClustVar : Clustering hiérarchique de variables	5
3.2	Méthodes de la classe HClustVar	8
3.3	KmeansVariables : K-means de variables	9
3.4	Méthodes de la classe KmeansVariables	11
3.5	ModCluster : Clustering de modalités	12
3.6	Méthodes de la classe ModCluster	13
4	Architecture du package	14
4.1	Structure générale	14
4.2	Application Shiny	15
5	Analyse de complexité algorithmique	16
5.1	Complexité théorique	16
5.2	Mesures expérimentales	16
6	Conclusion	18
6.1	Perspectives	18

1 Introduction

1.1 Contexte et motivation

Le clustering de variables est une technique d'analyse exploratoire visant à regrouper des variables corrélées en clusters homogènes. Contrairement au clustering d'observations classique (k-means, CAH), cette approche s'intéresse à la structure de corrélation entre les variables plutôt qu'à la similarité entre individus.

Les applications du clustering de variables sont nombreuses :

- **Réduction de dimensionnalité** : identifier des groupes de variables redondantes
- **Interprétation** : comprendre la structure latente des données
- **Sélection de variables** : choisir un représentant par cluster
- **Pré-traitement pour la modélisation** : éviter la multicolinéarité

1.2 Objectifs du projet

Ce projet vise à développer un package R complet pour le clustering de variables et de modalités, proposant :

1. Trois algorithmes de clustering adaptés aux variables quantitatives, qualitatives et aux modalités
2. Des outils d'aide à la décision (sélection automatique du nombre de clusters)
3. Des méthodes d'interprétation riches (graphiques, tableaux, métriques)
4. Une interface utilisateur interactive via Shiny

Le package `VarClustering` suit les standards modernes de développement R (classes R6, documentation roxygen2, tests unitaires) et s'inspire de l'API scikit-learn pour sa simplicité d'utilisation.

1.3 Structure du rapport

Ce rapport présente :

- Section 2 : la méthodologie et le choix des implémentations
- Section 3 : la description détaillée des trois algorithmes implémentés
- Section 4 : l'architecture logicielle du package
- Section 5 : l'analyse de complexité algorithmique

2 Méthodologie

2.1 Clustering de variables vs clustering d'observations

Le clustering de variables diffère fondamentalement du clustering d'observations :

Aspect	Clustering d'observations	Clustering de variables
Objet	Lignes (individus)	Colonnes (variables)
Mesure	Distance euclidienne	Corrélation / V de Cramer
Centroïde	Moyenne des individus	Composantes latentes
Objectif	Segmenter les données	Comprendre les relations

TABLE 1 – Différences entre clustering d'observations et de variables

2.2 Approches existantes

2.2.1 Package ClustOfVar

Le package `ClustOfVar` [1] propose une approche hiérarchique basée sur :

- L'utilisation de l'analyse en composantes principales (ACP) pour les variables quantitatives
- L'analyse des correspondances multiples (ACM) pour les variables qualitatives
- Une métrique basée sur le rapport de corrélation

2.2.2 Méthode Varclus

Méthode basée sur le traitement de variables quantitatives, par l'utilisation élégante d'ACP et de rotation de facteurs afin de répartir les corrélations sur les composantes principales pour segmenter les groupes [2].

2.3 Choix des algorithmes

Afin de couvrir une large gamme de problématiques, nous avons choisi d'implémenter les 3 algorithmes suivants :

- Un algorithme polyvalent basé sur les matrices de distances pour effectuer une classification ascendante hiérarchique. Cet algorithme sera pensé pour traiter la plupart des problématiques sur des données de taille moyenne, considérant la limitation des algorithmes de classification ascendante, proposant des complexités supérieures à $O(n)$ voire $O(n^3)$. Les algorithmes de CAH ont cependant l'avantage de présenter des visualisations pratiques pour l'utilisateur : un dendrogramme, absent des méthodes par réallocation, permettant de visualiser efficacement le nombre de classes à considérer.
- Un algorithme de réallocation (K-means) basé sur les composantes latentes. Bien plus efficace que les algorithmes CAH ($O(n)$), c'est un complément parfait au premier algorithme présenté, notamment pour le traitement de variables quantitatives sur des datasets à haute dimensionnalité (que l'on retrouve notamment en NLP).
- Enfin, un dernier algorithme basé à nouveau sur une CAH sur une matrice de distance de Dice, permettant de traiter les variables qualitatives avec plus de profondeur, décomposant la problématique au niveau des modalités via le traitement de tableaux disjonctifs complets.

3 Algorithmes implémentés

3.1 HClustVar : Clustering hiérarchique de variables

3.1.1 Principe général

L'algorithme HClustVar implémente une Classification Ascendante Hiérarchique (CAH) sur une matrice de distance. Il construit un dendrogramme en fusionnant progressivement les variables les plus similaires, permettant d'explorer la structure hiérarchique des corrélations.

L'algorithme supporte trois types de variables :

- **Quantitatifs** : utilisation de la corrélation ou de la corrélation au carré de Pearson
- **Qualitatifs** : utilisation du V de Cramer
- **Mixtes** : discrétisation des variables quantitatives à l'aide de quantiles puis utilisation du V de Cramer

3.1.2 Mesures de similarité

Variables quantitatives Pour deux variables quantitatives X_i et X_j , la similarité est basée soit sur le coefficient de détermination, soit sur la corrélation brute. Cette différence permet de prendre en considération les variables anti-corrélées. C'est à l'utilisateur de choisir s'il souhaite opposer des variables de corrélation négative (utilisation de la corrélation brute) ou s'il souhaite les associer en utilisant la corrélation au carré, permettant d'éliminer le signe de la métrique de similarité.

$$S(X_i, X_j) = r^2(X_i, X_j) \quad (1)$$

ou

$$S(X_i, X_j) = r(X_i, X_j) \quad (2)$$

Pour générer la dissimilarité, métrique qui nous servira à peupler notre matrice de distance, nous appliquerons l'équation suivante :

$$d(X_i, X_j) = \sqrt{1 - S(X_i, X_j)} \quad (3)$$

Variables qualitatives Pour deux variables qualitatives, nous utilisons le V de Cramer comme indicateur de similarité :

$$V(X_i, X_j) = \sqrt{\frac{\chi^2/n}{\min(k_i - 1, k_j - 1)}} \quad (4)$$

où χ^2 est la statistique du chi-deux, n le nombre d'observations, et k_i , k_j le nombre de modalités de chaque variable.

Nous calculons ensuite la dissimilarité via la formule suivante :

$$d(X_i, X_j) = 1 - V(X_i, X_j) \quad (5)$$

Il est à noter que le calcul des V de Cramer (passant par la mesure du χ^2 peut devenir intensif en ressources. Nous nous attendons à une plus faible performance de l'algorithme

utilisé dans ces conditions. Les jeux de données qualitatifs ont tendance à cependant être moins volumineux (en colonnes) que les données quantitatives, permettant à l'algorithme de s'en sortir convenablement pour une première exploration.

Variables mixtes Le traitement des variables mixtes peut poser plusieurs problèmes. Il n'est pas possible de comparer directement les corrélations de Pearson avec les V de Cramer ou les rapports de corrélation. Générer une matrice mixte de corrélation nécessite de prendre en considération la distribution des éléments manipulés, et ne peut se faire que par un lourd processus de calcul passant par les corrélations polychoriques [3]. Afin de simplifier le processus, nous avons choisi d'implémenter une discrétisation des variables qualitatives en utilisant les quantiles 0.25, 0.50, 0.75, puis d'appliquer la mesure de liaison via le V de Cramer pour toutes les variables, homogénéisant ainsi la génération de la matrice de liaison, puis la matrice de distance. Nous retombons donc dans le cas des variables qualitatives pour le calcul.

3.1.3 Critère d'agrégation de Ward

Le critère de Ward minimise l'augmentation de l'inertie intra-classe lors de la fusion de deux clusters. Pour le clustering de variables, on utilise une version adaptée basée sur la perte d'homogénéité.

Soit C_k un cluster de variables. Son homogénéité est définie par :

$$H(C_k) = \sum_{X_j \in C_k} r^2(X_j, c_k) \quad (6)$$

où c_k est la première composante principale du cluster.

Le critère de fusion de deux clusters C_a et C_b en C_{ab} est :

$$\Delta H = H(C_a) + H(C_b) - H(C_{ab}) \quad (7)$$

On choisit à chaque étape la fusion qui minimise ΔH .

La méthode de Ward évite le recalcul explicite des centroïdes grâce à la formule de Lance-Williams, qui permet une mise à jour récursive des distances. Lorsque deux clusters C_a et C_b fusionnent en C_{ab} , la distance à un troisième cluster C_c se calcule directement :

$$d(C_{ab}, C_c) = \frac{(n_a + n_c)d(C_a, C_c) + (n_b + n_c)d(C_b, C_c) - n_c d(C_a, C_b)}{n_a + n_b + n_c} \quad (8)$$

où n_a , n_b et n_c sont les effectifs des clusters. Cette formule récursive nécessite uniquement les distances précédentes et les tailles des clusters, évitant ainsi le recalcul coûteux des centroïdes via les méthodes factorielles et des distances euclidiennes à chaque itération. Cela réduit significativement la complexité calculatoire de l'algorithme.

3.1.4 Algorithme

Algorithm 1 HClustVar - Clustering hiérarchique de variables

Entrée: Matrice de données $X \in \mathbb{R}^{n \times p}$, méthode d'agrégation

Sortie: Dendrogramme, partition pour K clusters

```
1: Initialisation : Chaque variable forme son propre cluster
2: Calculer la matrice de distance  $D$  entre toutes les paires de variables
3:  $n\_clusters \leftarrow p$ 
4: while  $n\_clusters > 1$  do
5:   Trouver  $(i, j) = \arg \min_{a \neq b} D(C_a, C_b)$ 
6:   Fusionner  $C_i$  et  $C_j$  en  $C_{ij}$ 
7:   Mettre à jour  $D$  selon la méthode d'agrégation choisie
8:    $n\_clusters \leftarrow n\_clusters - 1$ 
9:   Enregistrer la fusion dans le dendrogramme
10: end while
11: return Dendrogramme
```

3.1.5 Méthodes d'agrégation disponibles

- **ward.D** : critère de Ward modifié utilisant $\sqrt{d^2}$
- **ward.D2** : critère de Ward original [4] minimisant l'inertie intra-classe (recommandé)
- **single** : linkage simple, distance minimale entre deux éléments des clusters
- **complete** : linkage complet, distance maximale entre deux éléments des clusters
- **average** : linkage moyen non pondéré (UPGMA), moyenne arithmétique des distances
- **mcquitty** : linkage moyen pondéré (WPGMA), moyenne des distances entre clusters
- **median** : linkage médian pondéré (WPGMC), utilise la médiane des distances
- **centroid** : linkage centroïde non pondéré (UPGMC), distance euclidienne entre centroïdes

3.1.6 Prédiction

L'algorithme présente la possibilité de prédire le cluster choisi après coupure de l'arbre et sélection du nombre de clusters. Cette prédiction est effectuée en calculant la distance des variables illustratives aux centroides des clusters. Il est ainsi nécessaire de passer par les méthodes factorielles (ACP, ACM ou AFDM pour des clusters peuplés de variables quantitatives, qualitatives, ou mixtes) pour générer la composante latente (premier axe factoriel) sur lequel il est possible de calculer une corrélation au carré (pour les variables quantitatives) ou un rapport de corrélation (pour les variables qualitatives). Afin de conserver une cohérence avec les métriques utilisés, plusieurs opérations sont effectuées :

- Les composantes latentes des centroïdes sont vérifiées et renversées pour pointer dans la même direction que les variables qui les composent afin de prendre en compte le signe de corrélation lors de la prédiction si l'utilisateur a choisi d'utiliser la corrélation brute.

- Le calcul des distances des variables illustratives dépend de la méthode d'agrégation utilisée : ainsi, une méthode autre que Ward ou centroïde utilisera la distance par rapport aux autres variables composant les clusters, calculée via les corrélations ou les corrélations au carré, afin de sélectionner une attribution par maximum, minimum, moyenne ou médiane.

3.2 Méthodes de la classe HClustVar

La classe `HClustVar` implémente le clustering hiérarchique de variables avec les méthodes principales suivantes :

TABLE 2 – Méthodes principales et sorties de `HClustVar`

Méthode	Description	Sortie
<code>fit(data)</code>	Calcule la matrice de distances et construit l'arbre hiérarchique	Objet <code>hclust</code> stocké
<code>cut_tree(k)</code>	Coupe l'arbre en k clusters et calcule les centroïdes (1ère composante principale)	Vecteur de labels (1 à k)
<code>summary()</code>	Statistiques détaillées sur les clusters	Liste avec 6 éléments (voir tableau 3)
<code>predict(new_data)</code>	Affecte de nouvelles variables aux clusters existants	Liste : <code>labels</code> (vecteur) + <code>proximities</code> (dataframe)
<code>plot_dendrogram(k)</code>	Visualise l'arbre hiérarchique avec rectangles colorés si $k > 0$	Graphique
<code>plot_agg_levels()</code>	Méthode du coude pour déterminer le k optimal (distance perpendiculaire)	Graphique
<code>plot_silhouette()</code>	Diagramme de silhouette pour évaluer la qualité du clustering	Graphique + vecteur de coefficients
<code>mds_projection()</code>	Projection MDS 2D des variables	Graphique

TABLE 3 – Contenu de la sortie `summary()`

Élément	Description
<code>clust_summary</code>	Dataframe : <code>cluster</code> , <code>n_members</code> , <code>var_explained</code> (valeur propre), <code>prop_explained</code> , <code>avg_silhouette</code>
<code>clust_members</code>	Dataframe : <code>cluster</code> , <code>own_cluster_R2</code> , <code>next_closest_R2</code> , <code>1 - R2_ratio</code> , <code>silhouette</code>
<code>centroids_correlations</code>	Dataframe : corrélations (r et r^2) entre les centroïdes des clusters
<code>all_clusters_R2</code>	Dataframe : R^2 de chaque variable avec tous les clusters
<code>avg_silhouette</code>	Valeur numérique : coefficient de silhouette moyen sur toutes les variables
<code>total_var_explained</code>	Valeur numérique : pourcentage de variance totale expliquée

Paramètres principaux du constructeur :

- `vartype` : "auto", "quant", "qual", "mixed"
- `dist.metric` : "r" (corrélation), "rsquare" (R^2 , défaut)
- `cah.method` : "ward.D" (défaut), "ward.D2", "single", "complete", "average", etc.

3.3 KmeansVariables : K-means de variables

3.3.1 Principe général

Le K-means de variables adapte l'algorithme k-means classique au contexte du clustering de variables. L'objectif est de partitionner un ensemble de p variables $\{X_1, \dots, X_p\}$ en K clusters homogènes en maximisant la corrélation intra-cluster.

3.3.2 Métrique de distance

La distance entre une variable X_j et le centroïde c_k d'un cluster est définie par :

$$d(X_j, c_k) = \sqrt{1 - \rho^2(X_j, c_k)} \quad (9)$$

ou

$$d(X_j, c_k) = \sqrt{1 - \rho(X_j, c_k)} \quad (10)$$

où $\rho(X_j, c_k)$ est le coefficient de corrélation de Pearson.

Propriétés :

- $d \in [0, 1]$
- $d = 0$ si $|\rho| = 1$ (corrélation parfaite)
- $d = 1$ si $\rho = 0$ (variables non corrélées)
- $d > 1$ si $\rho = -1$ (variables anti corrélées si utilisation de la corrélation simple)

3.3.3 Calcul du centroïde

Pour un cluster C_k , le centroïde c_k est la première composante principale obtenue par ACP. Cela nous donne une variable latente, équivalent à une variable moyenne, sur laquelle il est possible de mesurer des corrélations pour estimer la proximité des autres variables aux clusters.

3.3.4 Algorithme

Algorithm 2 K-means de variables

Entrée: Matrice de données $X \in \mathbb{R}^{n \times p}$, nombre de clusters K

Sortie: Partition $\mathcal{P} = \{C_1, \dots, C_K\}$, centroïdes $\{c_1, \dots, c_K\}$

```

1: Initialisation : Affecter aléatoirement les  $p$  variables aux  $K$  clusters
2:  $converged \leftarrow \text{False}$ 
3: while  $\neg converged$  do
4:   // Étape 1 : Calcul des centroïdes (ACP)
5:   for  $k = 1$  to  $K$  do
6:      $c_k \leftarrow$  première composante principale de  $C_k$ 
7:   end for
8:   // Étape 2 : Réallocation des variables
9:   for  $j = 1$  to  $p$  do
10:     $k^* \leftarrow \arg \min_k d(X_j, c_k)$ 
11:    Affecter  $X_j$  au cluster  $C_{k^*}$ 
12:   end for
13:   // Étape 3 : Vérification convergence
14:   if partition inchangée then
15:      $converged \leftarrow \text{True}$ 
16:   end if
17: end while
18: return  $\mathcal{P}, \{c_1, \dots, c_K\}$ 

```

3.3.5 Initialisations multiples

Pour éviter les optima locaux, l'algorithme effectue n_{init} exécutions avec des initialisations aléatoires différentes et conserve la solution avec l'inertie maximale.

3.3.6 Sélection automatique de K

Méthode du coude On calcule l'inertie totale pour $K \in \{K_{min}, \dots, K_{max}\}$ et on cherche le "coude" de la courbe.

Coefficient de silhouette Pour chaque variable X_j :

Attention : la sélection automatique du K nécessite plusieurs itérations de l'algorithme, pouvant nécessiter une grande capacité de calcul si les données possèdent trop de colonnes.

$$s(X_j) = \frac{b(X_j) - a(X_j)}{\max\{a(X_j), b(X_j)\}} \quad (11)$$

où $a(X_j)$ est la distance au centroïde propre et $b(X_j)$ la distance au centroïde le plus proche.

3.3.7 Prédiction

Même méthode utilisée qu'avec HClustVar ci-dessus.

3.4 Méthodes de la classe KmeansVariables

La classe `KmeansVariables` implémente le clustering par k-means de variables quantitatives avec les méthodes principales suivantes :

TABLE 4 – Méthodes principales et sorties de `KmeansVariables`

Méthode	Description	Sortie
<code>fit(data)</code>	Effectue le clustering par k-means avec multiples initialisations	Modèle ajusté (clusters, centroïdes, inertie stockés)
<code>predict(new_data)</code>	Prédit l'appartenance de nouvelles variables aux clusters existants	Liste : clusters (vecteur), distances (matrice), correlations (matrice)
<code>summary(print_summary, top_n)</code>	Statistiques détaillées sur les clusters	Liste avec 7 éléments (voir tableau 5)
<code>silhouette()</code>	Calcule les coefficients de silhouette	Dataframe avec silhouette par variable
<code>calinski_harabasz()</code>	Calcule l'indice de Calinski-Harabasz	Valeur numérique (qualité du clustering)
<code>intra_correlation()</code>	Calcule les corrélations intra-cluster moyennes	Dataframe avec corrélation moyenne par cluster
<code>contributions()</code>	Calcule les contributions des variables aux clusters	Dataframe avec contributions par variable
<code>correlation_table(round_digits)</code>	Matrice de corrélations variables-centroïdes	Dataframe avec corrélations arrondies
<code>plot_elbow(k_range)</code>	Méthode du coude pour sélection de k optimal	Graphique
<code>plot_contributions(top_n)</code>	Visualise les variables les plus contributives	Graphique
<code>plot_projection()</code>	Projection PCA des variables et clusters	Graphique

TABLE 5 – Contenu de la sortie `summary()`

Élément	Description
<code>clust_summary</code>	Dataframe : cluster , n_members , variation_explained (valeur propre), proportion_explained
<code>clust_members</code>	Dataframe : cluster , own_cluster_R2 , next_closest_R2 , 1 - R2_ratio
<code>top_variables</code>	Dataframe : top n variables contributives par cluster (cluster_id , variable , r_squared , rank)
<code>centroids_correlations</code>	Matrice : corrélations entre les centroïdes des clusters
<code>avg_silhouette</code>	Valeur numérique : coefficient de silhouette moyen
<code>total_var_explained</code>	Valeur numérique : proportion de variance totale expliquée
<code>all_clusters_R2</code>	Dataframe : R^2 de chaque variable avec tous les clusters

Paramètres principaux du constructeur :

- `n_clusters` : entier ou "auto" (sélection automatique du k optimal)

- `distance_metric` : "r_squared" (R^2 , défaut) ou "r_signed" (corrélation signée)
- `max_iter` : nombre maximum d'itérations (défaut : 100)
- `n_init` : nombre d'initialisations aléatoires (défaut : 3)
- `random_state` : graine aléatoire pour reproductibilité
- `k_range` : plage de k à tester si `n_clusters` = "auto" (défaut : 2 :10)
- `selection_method` : "silhouette", "calinski" ou "all" (défaut : "silhouette")

3.5 ModCluster : Clustering de modalités

3.5.1 Principe général

L'algorithme ModCluster implémente un clustering hiérarchique des **modalités** (catégories) plutôt que des variables. Cette approche est particulièrement adaptée à l'analyse de données catégorielles où l'on souhaite identifier des groupes de modalités qui apparaissent ensemble fréquemment et présente une complémentarité avec le clustering de variables qualitatives HClustVar.

3.5.2 Tableau disjonctif complet

Les données catégorielles sont transformées en un tableau disjonctif complet (matrice indicatrice) :

$$Z_{im} = \begin{cases} 1 & \text{si l'individu } i \text{ possède la modalité } m \\ 0 & \text{sinon} \end{cases} \quad (12)$$

3.5.3 Distance de Dice

La distance entre deux modalités m_1 et m_2 est basée sur le coefficient de Dice :

$$D_{Dice}(m_1, m_2) = \frac{1}{2} \sum_{i=1}^n (z_{im_1} - z_{im_2})^2 \quad (13)$$

Cette distance mesure la dissimilarité entre deux modalités en fonction des individus qui possèdent l'une mais pas l'autre.

Interprétation :

- $D = 0$: les deux modalités apparaissent toujours ensemble
- D élevé : les modalités sont mutuellement exclusives

3.5.4 Algorithme

Algorithm 3 ModCluster - Clustering de modalités

Entrée: Données catégorielles X , méthode d'agrégation

Sortie: Dendrogramme des modalités

- 1: Construire le tableau disjonctif complet Z
 - 2: Calculer la matrice de distance de Dice entre toutes les modalités
 - 3: Appliquer la CAH avec la méthode d'agrégation choisie
 - 4: **return** Dendrogramme, coordonnées ACM
-

3.5.5 Prédiction de nouvelles observations

Pour un nouvel individu, on calcule sa distance moyenne aux modalités de chaque cluster et on l'affecte au cluster le plus proche. La proximité au cluster dépend des méthodes d'agrégation utilisées lors de la CAH, ainsi :

- average : Distance moyenne avec les individus des clusters.
- simple : Distance minimale avec les individus aux clusters.
- complete : Distance maximale avec les individus aux clusters.

3.6 Méthodes de la classe ModCluster

La classe `ModCluster` implémente le clustering hiérarchique de modalités basé sur la distance de Dice avec les méthodes principales suivantes :

TABLE 6 – Méthodes principales et sorties de ModCluster

Méthode	Description	Sortie
<code>fit(data)</code>	Construit la matrice disjonctive, calcule les distances de Dice et effectue la CAH	Modèle ajusté (distances, arbre, ACM stockés)
<code>cut_tree(k)</code>	Coupe l'arbre hiérarchique en k clusters	Self (pour chaînage de méthodes)
<code>predict(new_data)</code>	Prédit l'appartenance de nouvelles observations aux clusters	Liste : prediction (vecteur), distances (dataframe)
<code>summary()</code>	Statistiques détaillées sur les clusters	Liste avec 6 éléments (voir tableau 7)
<code>get_dice_matrix()</code>	Retourne la matrice de distances de Dice	Matrice symétrique de distances
<code>get_cluster_table()</code>	Table simple des modalités avec clusters	Dataframe : Modality , Cluster , Frequency
<code>plot_dendrogram(k)</code>	Visualise l'arbre hiérarchique avec branches colorées	Graphique
<code>plot_mca(axes)</code>	Projection ACM des modalités par cluster	Graphique
<code>plot_mca_with_new()</code>	Projection ACM avec nouvelles observations	Graphique + liste de coordonnées
<code>plot_silhouette()</code>	Diagramme de silhouette pour évaluer la qualité	Graphique + dataframe de silhouettes
<code>plot_heights()</code>	Méthode du coude pour sélection de k	Graphique

TABLE 7 – Contenu de la sortie `summary()`

Élément	Description
<code>clust_summary</code>	Dataframe : <code>Cluster</code> , <code>n_members</code> , <code>within_var</code> (variance intra-cluster), <code>avg_silhouette</code>
<code>modality_quality</code>	Dataframe : <code>Modality</code> , <code>Cluster</code> , <code>own_cluster_distance</code> , <code>next_closest_distance</code> , <code>ratio</code>
<code>inter_cluster_distances</code>	Dataframe : distances moyennes entre paires de clusters (<code>Cluster_A</code> , <code>Cluster_B</code> , <code>avg_distance</code>)
<code>cluster_distances</code>	Dataframe : distance de chaque modalité à tous les clusters (<code>Modality</code> , <code>Cluster</code> , <code>Dist_Cluster_1</code> , ...)
<code>avg_silhouette</code>	Valeur numérique : coefficient de silhouette moyen sur toutes les modalités
<code>total_var_explained</code>	Valeur numérique : proportion de variance expliquée (R^2)

Paramètres principaux du constructeur :

- `method` : méthode de clustering ("hclust" uniquement, défaut)
- `n_dimensions` : nombre de dimensions ACM pour visualisation (défaut : 2)
- `hclust_method` : "single", "complete", "average" (défaut)

4 Architecture du package

4.1 Structure générale

Le package `VarClustering` suit l'architecture standard d'un package R.

```

VarClustering/
R/
  ClusteringBase.R      # Interface pour les classes (gestions des erreurs)
  HClustVar.R           # Clustering hiérarchique
  KmeansVariables.R     # K-means de variables
  ModClust.R            # Clustering de modalités
  metrics_kmeans.R      # Métriques pour K-means
  plot_kmeans.R         # Visualisations K-means
  app_ui.R              # Interface Shiny
  run_app.R             # Lancement de l'application
  app_server.R          # Logique Shiny
data/
  autos.rda
  canines.rda
  players.rda
  vote.rda
man/
  # Documentation (roxygen2)
tests/testthat/
  # Tests unitaires
vignettes/
  # Tutoriels
DESCRIPTION
  # Metadonnées

```

NAMESPACE

Exports

4.1.1 Interface commune

Afin de faciliter la programmation entre collaborateurs, nous avons implémenté une classe R6 de base, dont chacun des algorithmes hérite, et qui gère une grande partie des inputs utilisateurs. Cela permet de fournir non seulement des méthodes uniformes à la préparation des données avec une détection des variables quantitatives et qualitatives et leur sélection, mais aussi un squelette de base avec les méthodes obligatoires à implémenter dans chacun des algorithmes.

```
1 # Constructeur
2 model$new(n_clusters, ...)
3
4 # Methodes principales
5 model$fit(data)           # Apprentissage
6 model$predict(new_data)  # Variables illustratives
7 model$summary()          # Resume structure
8 model$print()            # Impression personnalisee
9
10 # Proprietes
11 private$.labels          # Labels des classes
12 private$.n_clusters      # Nombre de clusters
13 private$.quanti_indices  # Indice des variables quantitatives
14 private$.quali_indices   # Indice des variables qualitatives
```

Listing 1 – Interface commune des classes

4.2 Application Shiny

L'application Shiny permet d'utiliser les trois algorithmes sans écrire de code R :

```
1 library(VarClustering)
2 varclust_gui()
```

Listing 2 – Lancement de l'application Shiny

Fonctionnalités :

- Import de données CSV/Excel avec sélection automatique des séparateurs
- Configuration des variables (actives, illustratives, exclues)
- Choix de l'algorithme et des paramètres
- Visualisations des résultats
- Dynamisme de l'interface à l'aide des variables réactives

5 Analyse de complexité algorithmique

5.1 Complexité théorique

Algorithme	Temps	Espace	Paramètres
HClustVar	$O(p^2n)$	$O(p^2)$	$p = \text{variables}, n = \text{observations}$
KmeansVariables	$O(t \cdot np^2)$	$O(np)$	$t = \text{itérations}$
ModCluster	$O(m^2n)$	$O(m^2)$	$m = \text{modalités}$

TABLE 8 – Complexité algorithmique théorique

5.2 Mesures expérimentales

Des mesures de complexité ont été effectuées sur des datasets simples (autos et vote) dont les lignes et les colonnes ont progressivement été doublées à chaque itération pour évaluer le temps de travail d'un ordinateur possédant les spécificités suivantes :

- **Processeur** : AMD Ryzen 7 7800X3D
 - 8 cœurs physiques, 16 threads logiques
 - Fréquence : 4,2 GHz
- **Mémoire vive** : 32 Go RAM
- **Système d'exploitation** : Microsoft Windows 11 Famille (Build 26200)
- **Architecture** : x64

TABLE 9 – Temps d'exécution des algorithmes de clustering (en secondes)

Algorithme	Type	Croissance	Taille	Temps (s)
HClustVar	qualitative	cols	448	13.176
HClustVar	qualitative	rows	2 227 200	0.066
HClustVar	quantitative	cols	4 096	1.585
HClustVar	quantitative	rows	168 960	0.002
KMeans	quantitative	cols	4 096	0.438
KMeans	quantitative	rows	168 960	0.093
ModClust	qualitative	cols	448	7.401
ModClust	qualitative	rows	2 227 200	2.009




FIGURE 1 – Complexité de HClustVar




FIGURE 2 – Complexité de KMeans

Les études ci-dessus montrent bien la complexité quadratique (ou plus) proportionnelle au nombre de colonnes des algorithmes à base de classifications ascendantes hiérarchiques. L'algorithme K-means présente une complexité linéaire et est bien plus rapide que les

autres, pouvant assurer la gestion de grandes dimensionnalités dans le cadre de clustering de variables quantitatives.

L'augmentation du nombre de lignes a un effet assez négligeable sur l'algorithme, n'impactant qu'assez peu les performances, dont la complexité augmente linéairement. C'est prévisible dans notre cas où nous traitons le clustering en colonnes.

6 Conclusion

Ce projet a permis de développer un package R complet pour le clustering de variables et de modalités, proposant :

- **HClustVar** : clustering hiérarchique adapté aux variables quantitatives, qualitatives et mixtes
- **KmeansVariables** : clustering par k-means avec centroïdes ACP et sélection automatique du nombre de clusters
- **ModCluster** : clustering de modalités basé sur la distance de Dice

Le package offre une architecture moderne (R6), des visualisations riches (dendrogrammes, projections factorielles, silhouettes), un summary donnant des tableaux complets des distances entre les clusters et les variables pour mieux visualiser leurs constitutions, ainsi qu'une application Shiny interactive.

6.1 Perspectives

Les améliorations futures pourraient inclure :

- Optimisation des performances (via parallélisation), notamment pour le traitement des variables mixtes/quantitatives pour l'algorithme HClustVar où le calcul de la matrice de cramer et la discrétisation ralentissent le programme
- Une meilleure gestion des dépendances des classes ainsi que des méthodes communes aux 3 classes. Il faudrait dans l'idéal refactorer l'application de façon à créer des sous-classes gérant la visualisation, les calculs ou les sorties, permettant d'alléger les classes actuelles, assez lourdes, et uniformiser les sorties.

Références

- [1] Marie CHAVENT et al. “ClustOfVar : An R Package for the Clustering of Variables”. In : *Journal of Statistical Software* 50.13 (2012), p. 1-16. DOI : [10.18637/jss.v050.i13](https://doi.org/10.18637/jss.v050.i13).
- [2] Evelyne VIGNEAU et El Mostafa QANNARI. “Clustering of Variables Around Latent Components”. In : *Communications in Statistics - Simulation and Computation* 32.4 (2003), p. 1131-1150. DOI : [10.1081/SAC-120023882](https://doi.org/10.1081/SAC-120023882).
- [3] I. OLKIN et R. F. TATE. “Multivariate correlation models with mixed discrete and continuous variables”. In : *The Annals of Mathematical Statistics* ().
- [4] Joe H. WARD. “Hierarchical Grouping to Optimize an Objective Function”. In : *Journal of the American Statistical Association* 58.301 (1963), p. 236-244.
- [5] El Mostafa QANNARI, Evelyne VIGNEAU et Philippe COURCOUX. “Une nouvelle distance entre variables. Application en classification”. In : *Revue de statistique appliquée* 46.2 (1998), p. 21-32. URL : http://www.numdam.org/item?id=RSA_1998__46_2_21_0.
- [6] Alexis BOULIN et al. “High-dimensional variable clustering based on sub-asymptotic maxima of a weakly dependent random process”. In : (2023). hal-03969058v2.
- [7] Sebastian FUCHS et Yuping WANG. “Hierarchical variable clustering based on the predictive strength between random vectors”. In : *International Journal of Approximate Reasoning* 170 (2024), p. 109185.
- [8] Ludovic LEBART, Alain MORINEAU et Marie PIRON. *Statistique exploratoire multidimensionnelle*. 4^e éd. Paris : Dunod, 2006, p. 439.
- [9] Ricco RAKOTOMALALA. *Clustering des modalités de variables catégorielles*. Tutoriel, Université Lyon 2. 2014.
- [10] Ricco RAKOTOMALALA. *Analyse des Correspondances Multiples (ACM)*. Tutoriel, Université Lyon 2.
- [11] Ricco RAKOTOMALALA. *Méthode des centres mobiles - Classification par partition*. Tutoriel, Université Lyon 2.
- [12] Ricco RAKOTOMALALA. *Classification de variables autour de composantes latentes*. Tutoriel, Université Lyon 2.
- [13] Ricco RAKOTOMALALA. *Classification de variables qualitatives*. Tutoriel, Université Lyon 2.
- [14] Ricco RAKOTOMALALA. *Clustering de Variables Quantitatives (Python)*. YouTube. 2023. URL : <https://www.youtube.com/watch?v=Wwq20qxS2E8>.
- [15] Ricco RAKOTOMALALA. *ACP + Rotation Quartimax et Clustering de variables (Python)*. YouTube. 2023. URL : <https://www.youtube.com/watch?v=HEBd3FCqQfk>.
- [16] Ricco RAKOTOMALALA. *Clustering Variables Qualitatives - Classification des modalités (Python)*. YouTube. 2023. URL : <https://www.youtube.com/watch?v=QVK3i44oGx8>.
- [17] Ricco RAKOTOMALALA. *Clustering des modalités de variables qualitatives via leur représentation factorielle (Python)*. YouTube. 2023. URL : https://www.youtube.com/watch?v=m2_UJXQhhzE.

- [18] Ricco RAKOTOMALALA. *Tanagra - ACP #5 - VARCLUS, clustering de variables*. YouTube. 2022. URL : <https://www.youtube.com/watch?v=0CQDHYaIF0k>.
- [19] Ricco RAKOTOMALALA. *Orange Data Mining – Clustering – CAH des variables*. YouTube. 2025. URL : <https://www.youtube.com/watch?v=Z7Wwcwts6MI>.