

VarClustering :

Un Package R pour le

Clustering de

Variables

**Algorithmes et outils pour
l'interprétation des
résultats**

M2 SISE 2025-2026

Axel CANO, Modou MBOUP,
Eugénie BARLET

11 décembre 2025

VarClustering : Clustering de Variables

Un package R complet et polyvalent

Regroupe des **variables plutôt que des observations** et propose plusieurs algorithmes pour identifier des **groupes de variables corrélées ou associées**.

Trois algorithmes complémentaires

- **HClustVar** : clustering hiérarchique
- **KmeansVariables** : clustering par k-means
- **ModCluster** : clustering de modalités

Feature	HClustVar	KmeansVariables	ModCluster
Quantitative variables	✓	✓	✗
Qualitative variables	✓	✗	✓
Mixed data	✓	✗	✗
Automatic type detection	✓	✓	✓
Multiple distance metrics	✓	✓	✓
Prediction on new observations	✓	✓	✓
Interactive visualizations	✓	✓	✓

Application

- **Réduction de dimensionnalité** avant régression/classification
- **Exploration de données** et compréhension des relations entre variables
- **Feature engineering** pour le machine learning

Fonctionnalités clés

- Sélection automatique du nombre de clusters (coude, silhouette)
- Visualisations riches (dendrogrammes, projection factorielles)
- Application Shiny interactive (utilisation sans codage)

Organisation et Architecture : l'approche R6

Un design orienté objet pour une implémentation intégrée

Architecture orientée objet

- Classes R6 avec héritage d'une **classe mère** pour garantir une gestion cohérente des inputs utilisateur.
- Encapsulation des calculs et **attributs privés** pour un contrôle strict de l'interface publique.

Librairies utilisées


devtools

testthat

roxygen2

Axes d'évolution

- **Classes auxiliaires** pour simplifier le code principal.
- **Standardisation** des sorties par héritage.



HClustVar : le clustering hiérarchique polyvalent

Spécificités de l'implémentation

Méthode de calcul

- Génération de la **matrice de distance** par :
 - Corrélation / corrélation carrée (variables quantitatives)
 - V de Cramer (variables qualitatives)
- Traitement des données mixtes par **discrétisation des variables quantitatives**.
- Utilisation de multiples **méthodes de linkage** en cohérence avec la méthode de prédiction.

Librairies utilisées

hclust

FactoMineR

Avantages


Polyvalence et visualisation **ergonomique** par dendrogramme.

Algorithme optimisé via vectorisation des calculs.



Inconvénients

L'utilisation de la CAH entraîne une **complexité en $O(n^3)$** malgré les optimisations : peu adapté aux gros datasets.



KmeansVariables : efficacité par réallocation

Centré sur les variables quantitatives et la haute dimensionnalité

Méthode de calcul

- Calcul des barycentres via **ACP** pour générer des composantes latentes.
- **Mesure de similarité au choix** : corrélation ou corrélation carrée.
- Implémentation **"from scratch"** du k-means pour personnaliser le calcul des barycentres.

Librairies utilisées

hclust

FactoMineR

Avantages

Temps d'exécution (dominé en $O(n)$) : adapté aux gros datasets.


Algorithme optimisé via vectorisation des calculs.



Inconvénients

Implémenté pour les **variables quantitatives seulement**.

Calcul de la silhouette long (itération de l'algorithme sur le nombre de clusters).



ModCluster : Clustering des Modalités

Une analyse fine des variables qualitatives

Méthode de calcul

→ Calcul de la matrice de distances via la **distance de Dice**.

→ Utilisation de la méthode '**hclust**' de R pour la CAH.

Librairies utilisées

hclust

FactoMineR

Avantages

Synergique avec **HClustVar**,
permet d'approfondir l'analyse des
variables qualitatives au niveau
des **modalités**.



Algorithme optimisé via
vectorisation des calculs.



Inconvénients



Algorithme de complexité $O(n^3)$:
peu adapté aux gros datasets.



Les sorties communes : validation et visualisation

Valoriser l'interprétation et l'aide à la décision


Sorties standardisées

→ `summary()` livre 4 tableaux d'étude du clustering pour une analyse approfondie :

- Résumé des clusters (effectifs, variance, proportion expliquée)
- Relations entre clusters (corrélations et distances)
- Attribution des variables aux clusters
- Vue d'ensemble des corrélations variables/clusters

→ Visualisation dans un espace factoriel adapté.

→ Screeplot de la silhouette pour le choix du nombre de clusters.



L'application interactive RShiny

Interface complète pour l'exploitation des algorithmes

Objectif : accessibilité et interactivité

→ Permettre l'utilisation de toutes les fonctionnalités du package **sans connaissance approfondie de R**.

→ Offrir une **interface graphique intuitive** pour les utilisateurs non-techniques.

Fonctionnalités clés

Interface utilisateur intuitive : chargement des données, sélection des algorithmes, configuration des paramètres.

Import des données : importation facile (CSV, Excel) avec détection automatique des séparateurs et des types de variables.

Visualisations dynamiques : mise à jour en temps réel des graphiques (dendrogramme, silhouette) lors du changement de K.

The screenshot displays the 'Variable Clustering' RShiny application interface. The title bar reads 'Variable Clustering' and 'Interactive application for variable clustering'. The navigation bar includes tabs for 'Data Preview', 'Variable Configuration' (selected), 'Summary', 'Elbow Method', 'Factorial Projection', 'Contribution', and 'Predict'.

The 'Variable Configuration' section contains a 'Configure Variables' button and a message: 'Click the button to configure which variables to use in clustering and their types.'

The main content area is divided into three panels:

- Active Variables** (Green background): 'Variables used in clustering analysis'. It lists 39 variables(s): shooting, passing, dribbling, defending, physio, attacking_crossing, attacking_finishing, attacking_heading_accuracy, attacking_short_passing, and attacking_volleyes.
- Illustrative Variables** (Yellow background): 'Variables for interpretation only'. It lists 2 variable(s): skill_moves and pace.
- Excluded Variables** (Pink background): 'Variables completely ignored'. It states 'No excluded variables'.

The 'Complete Configuration' section at the bottom shows a table with columns 'Variable', 'Type', and 'Role'.

Variable	Type	Role
skill_moves	Quantitative	Illustrative
pace	Quantitative	Illustrative
shooting	Quantitative	Active

Conclusion et pistes d'amélioration

Bilan du projet et vision future

- **Package R fonctionnel et documenté :**
Documentation roxygen2 et tests unitaires pour la robustesse.
- **Trois algorithmes complémentaires :**
HClustVar (polyvalence), KmeansVariables (efficacité), ModCluster (modalités).
- **Interface utilisateur RShiny :**
Application interactive pour utilisation sans code R, avec visualisations et export des résultats.

Points forts du projet :

- Couverture complète des types de variables
- Outils d'aide à la décision intégrés
- Visualisations riches et interprétables

Perspectives d'évolution

- **Homogénéisation des sorties :**
Standardisation des objets de sortie pour une utilisation plus cohérente et intuitive entre les trois algorithmes.
- **Classe abstraite commune :**
Introduction d'une classe mère (ex. AbstractVarCluster) pour éviter la duplication de code et créer une architecture intégrée.

Axes de développement :

- Refactorisation avec classe abstraite
- Optimisation des performances
- Extension à d'autres types de données

Questions ?

Merci de votre attention.